

École Normale Supérieure de Marrakech
Université Cadi Ayyad

Module : Business Intelligence

Mini-projet : Étude de cas, processus ETL

Réalisé par : Marouane Chafiqi
Master TEE
Année universitaire 2026-2027

Table des matières

Introduction 3

1. Modèle de données 3

1.1 Axes d'analyse et dimensions . . . 3

1.2 Table de faits . . . 3

2. Schéma de flux ETL 4

3. Extraction 5

4. Transformations 5

5. Chargement 6

6. Requêtes d'indicateurs 9

Inscriptions par filière . . . 9

Inscriptions par région . . . 10

Taux de redoublement global . . . 10

Inscriptions par année universitaire et semestre . . . 10

Contrôle du chargement . . . 11

Conclusion 11

Introduction

Dans l'énoncé, une université gère ses inscriptions avec plusieurs bases de données séparées. Les données sont redondantes, parfois incohérentes, et il est long d'obtenir un rapport simple comme « le nombre d'inscriptions par filière et par région ». Pour résoudre ce problème, je construis un entrepôt de données (Data Warehouse) en étoile et je l'alimente avec un processus ETL (Extraction, Transformation, Chargement).

J'ai utilisé **Talaxie Open Studio for Data Integration 8.9.0** (un fork communautaire de Talend Open Studio, qui n'est plus distribué officiellement depuis janvier 2024, avec la même interface et les mêmes composants), Java 21, et MySQL 8 avec phpMyAdmin via WAMP. Les sources sont trois fichiers Excel fournis avec l'énoncé. La base cible s'appelle **dw_universite**.

1. Modèle de données

1.1 Axes d'analyse et dimensions

Les indicateurs demandés (inscriptions par filière, par région, par période, taux de redoublement) se découpent selon cinq axes, donc cinq dimensions :

Dimension	Contenu	Remarque
dim_etudiant	id_etudiant, nom, prenom, sexe, date_naissance	clé reprise de la source
dim_geographie	id_geo, ville, region	clé automatique ; 10 villes seulement
dim_filiere	id_filiere, nom_filiere, departement, niveau	clé reprise de la source
dim_temps	id_temps, date_complete, jour, mois, nom_mois, trimestre, semestre, annee, annee_universitaire	clé au format yyyymmdd
dim_statut	id_statut, type_statut	Inscrit, Redoublant, Désisté

J'ai mis la géographie dans sa propre table parce que beaucoup d'étudiants partagent la même ville : « inscriptions par région » devient alors une jointure avec une table de 10 lignes. La clé de dim_temps est un entier du type 20240921 : elle se lit facilement, se trie par ordre chronologique et se calcule directement depuis la date d'inscription.

1.2 Table de faits

La table **fait_inscription** a pour grain **une inscription par ligne**, car un étudiant peut avoir plusieurs inscriptions. Elle contient les clés vers les cinq dimensions, l'identifiant d'inscription d'origine et deux mesures : **montant_paye** (qu'on peut additionner) et **nb_inscriptions** (toujours égale à 1, pour compter facilement).

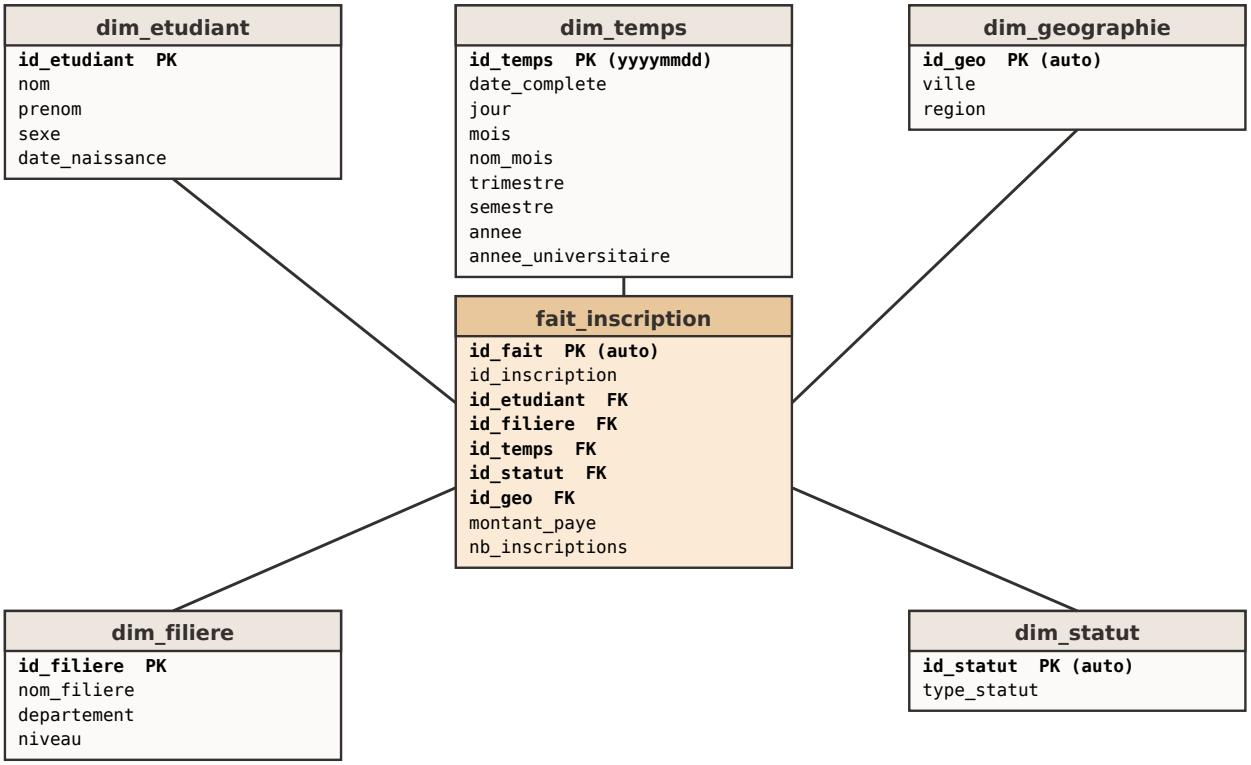


Figure 2 : Schéma en étoile de l'entrepôt

Écart avec l'énoncé : l'énoncé parle de numéro d'étudiant, de statut administratif, d'adresse et de « nouvel inscrit ». Ces champs n'existent pas dans les fichiers reçus. Le modèle s'appuie donc sur les champs réellement disponibles ; le statut prend les valeurs Inscrit, Redoublant et Désisté.

2. Schéma de flux ETL

Le flux est simple : les fichiers Excel sont lus (tFileInputExcel), transformés (tMap pour convertir et recalculer, tUniqRow pour supprimer les doublons), puis écrits dans MySQL (tDBOutput). Chaque table a son propre job, ce qui permet de localiser une erreur et de relancer un seul job.

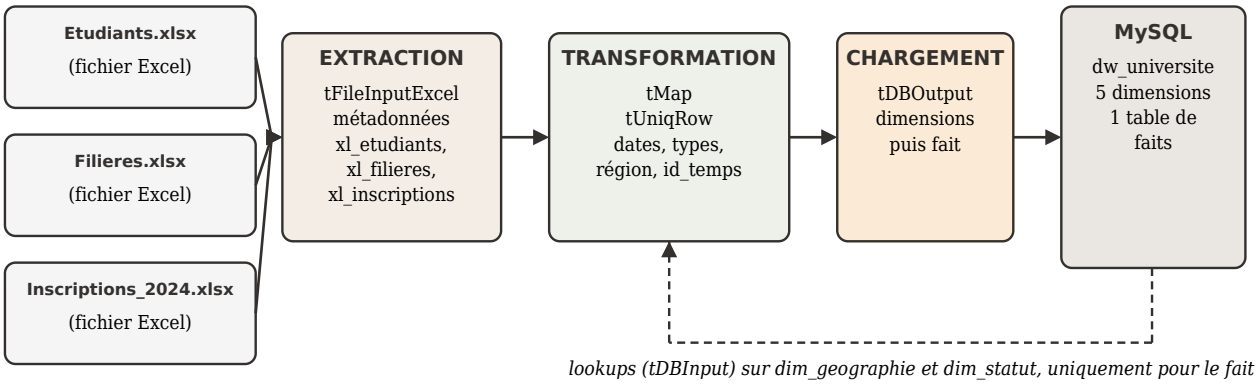


Figure 1 : Flux Extraction → Transformation → Chargement

Les six jobs sont : Job_Dim_Filiere, Job_Dim_Etudiant, Job_Dim_Geographie, Job_Dim_Statut, Job_Dim_Temps et Job_Fait_Inscription. Le job du fait relit en plus deux dimensions déjà chargées (composants tDBInput) pour retrouver les clés id_geo et id_statut.

3. Extraction

Fichier	Lignes	Colonnes
Etudiants.xlsx	100	id_etudiant, nom, prenom, sexe, date_naissance, ville, region
Filieres.xlsx	10	id_filiere, nom_filiere, departement, niveau, type
Inscriptions_2024.xlsx	100	id_inscription, id_etudiant, id_filiere, date_inscription, statut, montant_paye

Dans le Référentiel de Talaxie, j'ai créé une connexion à la base cible (**conn_dw**) et trois métadonnées Fichier Excel (**xl_etudiants**, **xl_filieres**, **xl_inscriptions**). Ainsi, chaque fichier est décrit une seule fois et réutilisé dans plusieurs jobs. Excel renvoie les dates sous forme de texte ; j'ai donc passé le schéma en Built-in pour déclarer les dates en type Date, au format yyyy-MM-dd.

4. Transformations

En examinant les fichiers, j'ai trouvé plusieurs problèmes de qualité. Le tableau résume ce que j'ai décidé pour chacun.

Problème constaté	Décision	Composant
83 étudiants sur 100 ont une région qui ne correspond pas à leur ville (ex. Tétouan en Souss-Massa)	Recalculer la région à partir de la ville	tMap + tUniqRow
Filière 9 (Biologie) : niveau = Licence mais type = Master	Alimenter niveau avec la colonne type	tMap
Dates lues comme du texte	Les déclarer en type Date (yyyy-MM-dd)	tFileInputExcel
Types incompatibles : sexe en Character, clé id_temps	Convertir en String, et id_temps en Integer	tMap
Pas de dimension temporelle dans les sources	La construire depuis la date d'inscription	tMap + tUniqRow
Villes, statuts et dates répétés	Dédoublonner les dimensions	tUniqRow
8 couples (étudiant, filière) répétés, soit 15 lignes	Les conserver : une ligne = une inscription	aucun
23 inscriptions avec montant_paye = 0	Conserver tel quel, sans inventer de montant	aucun

La région. C'est le point le plus important : l'indicateur « inscriptions par région » serait faux sans cette correction. J'ai considéré la ville comme fiable et recalculé la région : Rabat et Kenitra → Rabat-Salé ; Marrakech → Marrakech-Safi ; Fès et Meknès → Fès-Meknès ; Casablanca → Casablanca-Settat ; Tétouan et Tanger → Tanger-Tétouan-Al Hoceima ; Oujda → Oriental ; Agadir → Souss-Massa. Le tUniqRow ramène ensuite les 100 étudiants à 10 couples ville/région.

La dimension temps. Pour chaque date d'inscription, je calcule le jour, le mois, le nom du mois, le trimestre, le semestre (S1 de septembre à janvier, S2 de février à juin) et l'année universitaire (septembre 2024 → 2024-2025). La clé est calculée ainsi :

```
Integer.parseInt(TalendDate.formatDate("yyyyMMdd", date_inscription))
```

La même expression est utilisée dans le job du fait, donc la clé étrangère retombe toujours sur la bonne ligne de dim_temps. Les 100 inscriptions donnent 30 dates distinctes.

Les taux. Je ne stocke pas de taux dans l'entrepôt : un pourcentage ne s'additionne pas. Le taux de redoublement est calculé au moment de la requête (section 6).

5. Chargement

Les dimensions sont chargées d'abord, puis le fait, parce que le fait référence les dimensions. Tous les tDBOutput sont en mode Insérer. Voici les jobs des dimensions.

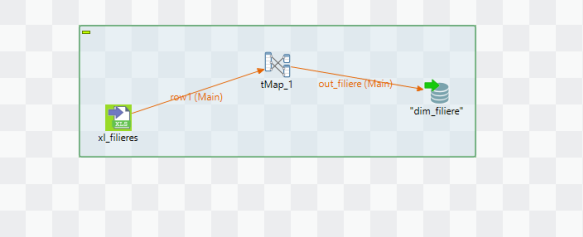


Figure 3 : Job_Dim_Filiere

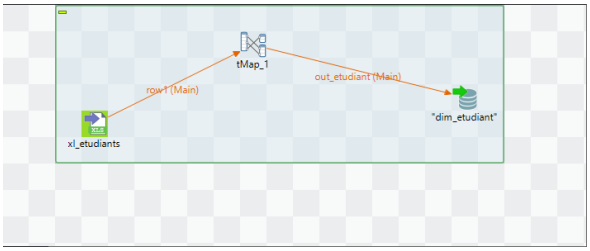


Figure 4 : Job_Dim_Etudiant

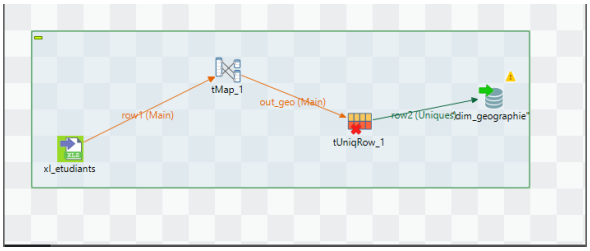


Figure 5 : Job_Dim_Geographie

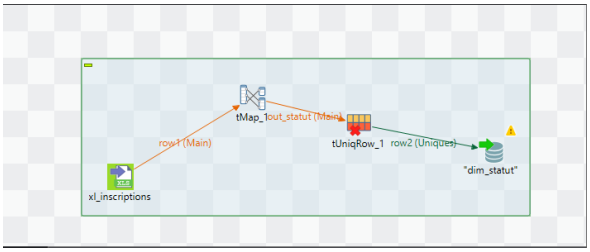


Figure 6 : Job_Dim_Statut

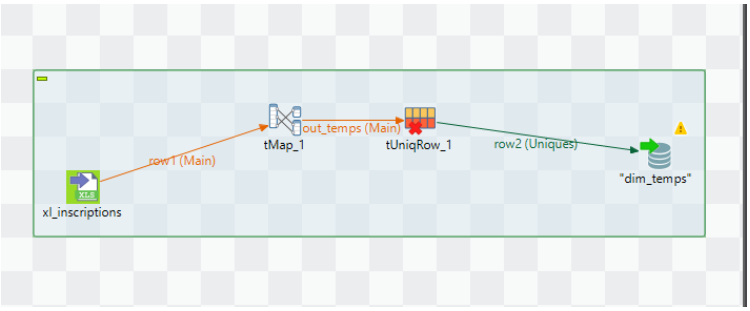


Figure 7 : Job_Dim_Temps

Job du fait. Le flux principal est xl_inscriptions. Un premier tMap le joint à xl_etudiants par id_etudiant pour récupérer la ville. Un second tMap fait deux lookups sur la base : dim_geographie (ville → id_geo) et dim_statut (statut → id_statut). Il calcule aussi id_temps et fixe nb_inscriptions à 1.

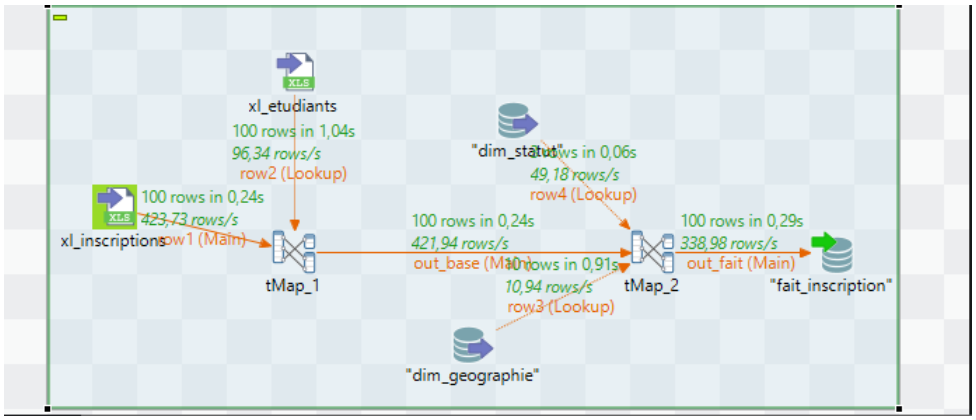


Figure 8 : Job_Fait_Inscription

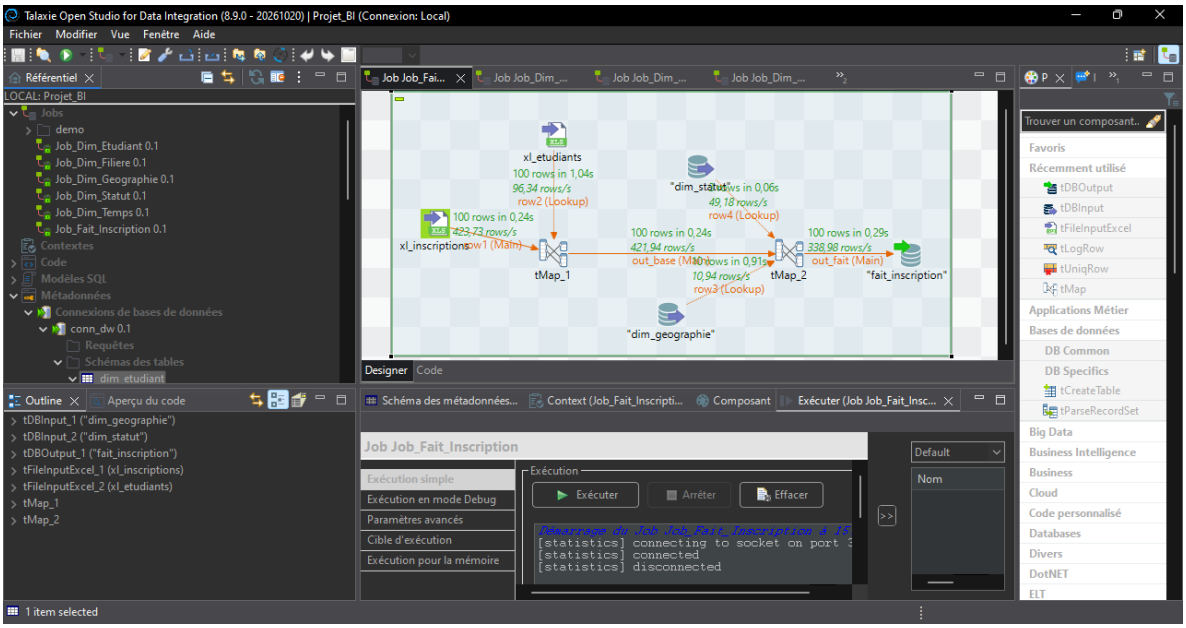


Figure 9 : Exécution du job du fait : 100 lignes lues, 100 lignes écrites

Vérification dans phpMyAdmin. Les effectifs obtenus : dim_filiere 10 lignes, dim_etudiant 100, dim_geographie 10, dim_statut 3, dim_temps 30, fait_inscription 100 (confirmé par la requête de contrôle de la section 6).

	id_filiere	nom_filiere	departement	niveau
Editer Copier Supprimer	1	Informatique	Sciences	Licence
Editer Copier Supprimer	2	Gestion	Économie	Licence
Editer Copier Supprimer	3	Marketing	Économie	Licence
Editer Copier Supprimer	4	Droit Privé	Droit	Licence
Editer Copier Supprimer	5	Mathématiques	Sciences	Licence
Editer Copier Supprimer	6	Physique	Sciences	Licence
Editer Copier Supprimer	7	Intelligence Artificielle	Sciences	Master
Editer Copier Supprimer	8	Réseaux	Sciences	Master
Editer Copier Supprimer	9	Biologie	Sciences	Master
Editer Copier Supprimer	10	Économie	Économie	Master

Tout cocher Avec la sélection : Editer Copier Supprimer Exporter

Figure 10 : dim_filiere (Biologie en Master)

	id_geo	ville	region
Editer Copier Supprimer	1	Tétouan	Tanger-Tétouan-Al Hoceima
Editer Copier Supprimer	2	Marrakech	Marrakech-Safi
Editer Copier Supprimer	3	Rabat	Rabat-Salé
Editer Copier Supprimer	4	Meknès	Fès-Meknès
Editer Copier Supprimer	5	Oujda	Oriental
Editer Copier Supprimer	6	Casablanca	Casablanca-Settat
Editer Copier Supprimer	7	Fès	Fès-Meknès
Editer Copier Supprimer	8	Tanger	Tanger-Tétouan-Al Hoceima
Editer Copier Supprimer	9	Kenitra	Rabat-Salé
Editer Copier Supprimer	10	Agadir	Souss-Massa

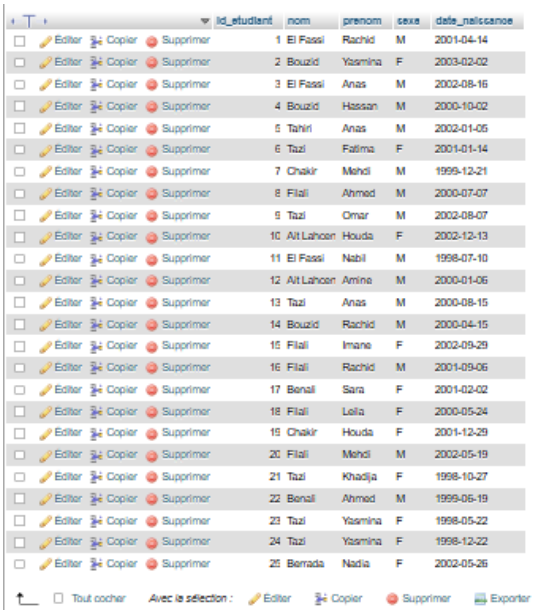
Tout cocher Avec la sélection : Editer Copier Supprimer Exporter

Figure 11 : dim_geographie (régions corrigées)



	id_statut	type_statut
Editer Copier Supprimer	1	Inscrit
Editer Copier Supprimer	2	Redoublant
Editer Copier Supprimer	3	Désisté

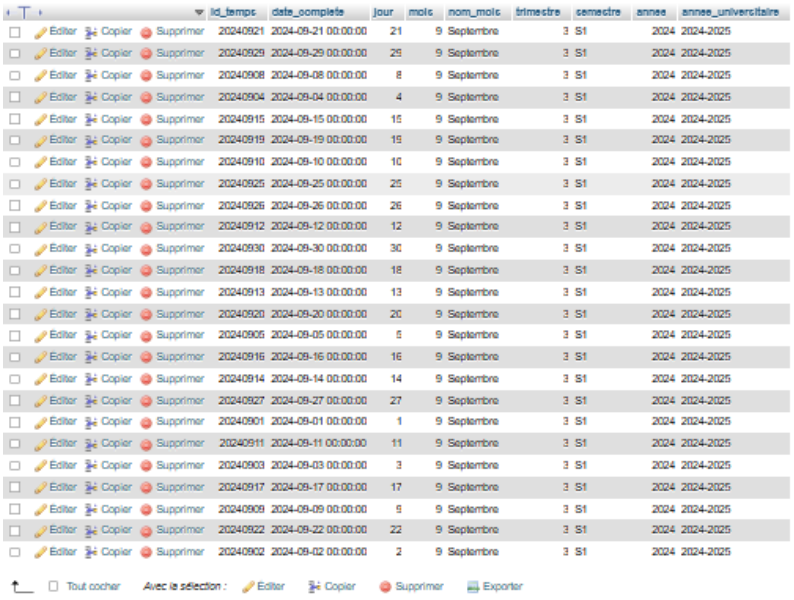
Figure 12 : dim_statut



	id_etudiant	nom	prenom	sexe	date_naissance
Editer Copier Supprimer	1	El Fassi	Rachid	M	2001-04-14
Editer Copier Supprimer	2	Bouzid	Yasmina	F	2003-02-02
Editer Copier Supprimer	3	El Fassi	Anas	M	2002-08-16
Editer Copier Supprimer	4	Bouzid	Hassan	M	2000-10-02
Editer Copier Supprimer	5	Tahiri	Anas	M	2002-01-05
Editer Copier Supprimer	6	Tazi	Fatima	F	2001-01-14
Editer Copier Supprimer	7	Chakir	Mehdi	M	1999-12-21
Editer Copier Supprimer	8	Filali	Ahmed	M	2000-07-07
Editer Copier Supprimer	9	Tazi	Omar	M	2002-08-07
Editer Copier Supprimer	10	Ait Lahcen	Houda	F	2002-12-13
Editer Copier Supprimer	11	El Fassi	Nabil	M	1998-07-10
Editer Copier Supprimer	12	Ait Lahcen	Amina	M	2000-01-06
Editer Copier Supprimer	13	Tazi	Anas	M	2000-08-15
Editer Copier Supprimer	14	Bouzid	Rachid	M	2000-04-15
Editer Copier Supprimer	15	Filali	Imane	F	2002-09-29
Editer Copier Supprimer	16	Filali	Rachid	M	2001-09-06
Editer Copier Supprimer	17	Benali	Sara	F	2001-02-02
Editer Copier Supprimer	18	Filali	Leila	F	2000-05-24
Editer Copier Supprimer	19	Chakir	Houda	F	2001-12-29
Editer Copier Supprimer	20	Filali	Mehdi	M	2002-05-19
Editer Copier Supprimer	21	Tazi	Khadija	F	1998-10-27
Editer Copier Supprimer	22	Benali	Ahmed	M	1999-06-19
Editer Copier Supprimer	23	Tazi	Yasmina	F	1998-05-22
Editer Copier Supprimer	24	Tazi	Yasmina	F	1998-12-22
Editer Copier Supprimer	25	Berrada	Nadia	F	2002-05-26

Tout cocher Avec la sélection : Editer Copier Supprimer Exporter

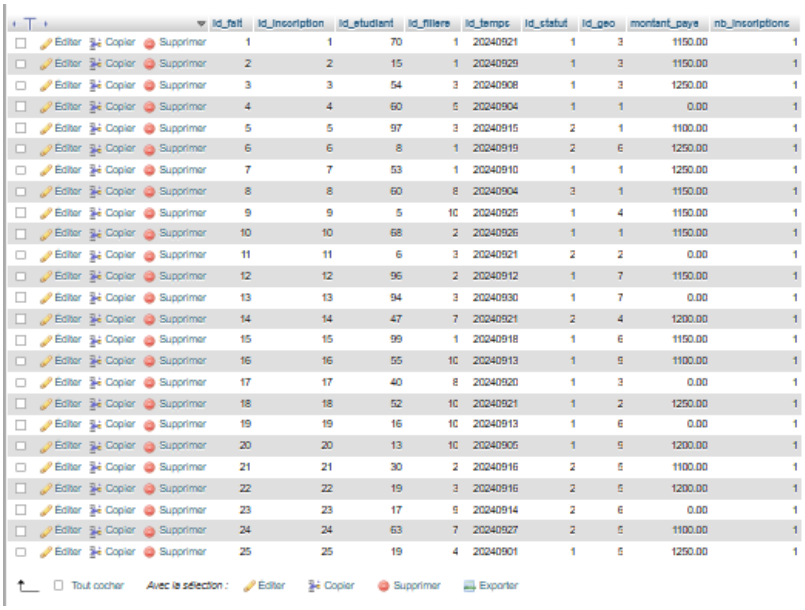
Figure 13 : dim_etudiant (extrait)



	id_temps	date_complete	jour	mois	nom_mois	trimestre	semestre	annee	annee_universitaire
Editer Copier Supprimer	20240921	2024-09-21 00:00:00	21	9	Septembre	3	S1	2024	2024-2025
Editer Copier Supprimer	20240929	2024-09-29 00:00:00	29	9	Septembre	3	S1	2024	2024-2025
Editer Copier Supprimer	20240908	2024-09-08 00:00:00	8	9	Septembre	3	S1	2024	2024-2025
Editer Copier Supprimer	20240904	2024-09-04 00:00:00	4	9	Septembre	3	S1	2024	2024-2025
Editer Copier Supprimer	20240915	2024-09-15 00:00:00	15	9	Septembre	3	S1	2024	2024-2025
Editer Copier Supprimer	20240919	2024-09-19 00:00:00	19	9	Septembre	3	S1	2024	2024-2025
Editer Copier Supprimer	20240910	2024-09-10 00:00:00	10	9	Septembre	3	S1	2024	2024-2025
Editer Copier Supprimer	20240925	2024-09-25 00:00:00	25	9	Septembre	3	S1	2024	2024-2025
Editer Copier Supprimer	20240926	2024-09-26 00:00:00	26	9	Septembre	3	S1	2024	2024-2025
Editer Copier Supprimer	20240912	2024-09-12 00:00:00	12	9	Septembre	3	S1	2024	2024-2025
Editer Copier Supprimer	20240930	2024-09-30 00:00:00	30	9	Septembre	3	S1	2024	2024-2025
Editer Copier Supprimer	20240918	2024-09-18 00:00:00	18	9	Septembre	3	S1	2024	2024-2025
Editer Copier Supprimer	20240913	2024-09-13 00:00:00	13	9	Septembre	3	S1	2024	2024-2025
Editer Copier Supprimer	20240920	2024-09-20 00:00:00	20	9	Septembre	3	S1	2024	2024-2025
Editer Copier Supprimer	20240905	2024-09-05 00:00:00	5	9	Septembre	3	S1	2024	2024-2025
Editer Copier Supprimer	20240916	2024-09-16 00:00:00	16	9	Septembre	3	S1	2024	2024-2025
Editer Copier Supprimer	20240914	2024-09-14 00:00:00	14	9	Septembre	3	S1	2024	2024-2025
Editer Copier Supprimer	20240927	2024-09-27 00:00:00	27	9	Septembre	3	S1	2024	2024-2025
Editer Copier Supprimer	20240901	2024-09-01 00:00:00	1	9	Septembre	3	S1	2024	2024-2025
Editer Copier Supprimer	20240911	2024-09-11 00:00:00	11	9	Septembre	3	S1	2024	2024-2025
Editer Copier Supprimer	20240903	2024-09-03 00:00:00	3	9	Septembre	3	S1	2024	2024-2025
Editer Copier Supprimer	20240917	2024-09-17 00:00:00	17	9	Septembre	3	S1	2024	2024-2025
Editer Copier Supprimer	20240909	2024-09-09 00:00:00	9	9	Septembre	3	S1	2024	2024-2025
Editer Copier Supprimer	20240922	2024-09-22 00:00:00	22	9	Septembre	3	S1	2024	2024-2025
Editer Copier Supprimer	20240902	2024-09-02 00:00:00	2	9	Septembre	3	S1	2024	2024-2025

Tout cocher Avec la sélection : Editer Copier Supprimer Exporter

Figure 14 : dim_temps (extrait)



	id_fait	id_inscription	id_etudiant	id_filiere	id_temps	id_statut	id_geo	montant_paye	nb_inscriptions
Editer Copier Supprimer	1	1	70	1	20240921	1	3	1150.00	1
Editer Copier Supprimer	2	2	15	1	20240929	1	3	1150.00	1
Editer Copier Supprimer	3	3	54	3	20240908	1	3	1250.00	1
Editer Copier Supprimer	4	4	60	5	20240904	1	1	0.00	1
Editer Copier Supprimer	5	5	97	3	20240915	2	1	1100.00	1
Editer Copier Supprimer	6	6	8	1	20240919	2	6	1250.00	1
Editer Copier Supprimer	7	7	53	1	20240910	1	1	1250.00	1
Editer Copier Supprimer	8	8	60	8	20240904	3	1	1150.00	1
Editer Copier Supprimer	9	9	5	10	20240925	1	4	1150.00	1
Editer Copier Supprimer	10	10	68	2	20240926	1	1	1150.00	1
Editer Copier Supprimer	11	11	6	3	20240921	2	2	0.00	1
Editer Copier Supprimer	12	12	96	2	20240912	1	7	1150.00	1
Editer Copier Supprimer	13	13	94	3	20240930	1	7	0.00	1
Editer Copier Supprimer	14	14	47	7	20240921	2	4	1200.00	1
Editer Copier Supprimer	15	15	99	1	20240918	1	6	1150.00	1
Editer Copier Supprimer	16	16	55	10	20240913	1	9	1100.00	1
Editer Copier Supprimer	17	17	40	8	20240920	1	3	0.00	1
Editer Copier Supprimer	18	18	52	10	20240921	1	2	1250.00	1
Editer Copier Supprimer	19	19	16	10	20240913	1	6	0.00	1
Editer Copier Supprimer	20	20	13	10	20240905	1	9	1200.00	1
Editer Copier Supprimer	21	21	30	2	20240916	2	6	1100.00	1
Editer Copier Supprimer	22	22	19	3	20240916	2	6	1200.00	1
Editer Copier Supprimer	23	23	17	9	20240914	2	6	0.00	1
Editer Copier Supprimer	24	24	63	7	20240927	2	6	1100.00	1
Editer Copier Supprimer	25	25	19	4	20240901	1	6	1250.00	1

Tout cocher Avec la sélection : Editer Copier Supprimer Exporter

Figure 15 : fait_inscription (extrait)

Si on relance un job sans vider sa table, les lignes sont insérées une deuxième fois : il faut donc vider les tables avant de rejouer un chargement.

6. Requêtes d'indicateurs

Ces quatre requêtes montrent que l'entrepôt répond aux besoins de l'énoncé avec une ou deux jointures seulement. Les résultats sont ceux obtenus dans phpMyAdmin.

Inscriptions par filière

```
SELECT f.nom_filiere, f.niveau, COUNT(*) AS nb_inscriptions
FROM fait_inscription fi
JOIN dim_filiere f ON fi.id_filiere = f.id_filiere
GROUP BY f.nom_filiere, f.niveau
ORDER BY nb_inscriptions DESC;
```

Elle classe les filières par demande. **Economie** arrive en tête avec 15 inscriptions, suivie de **Marketing** et **Biologie** (13 chacune). À l'autre bout, **Physique** n'en compte que 2 et **Réseaux** 6. Le total fait bien 100 inscriptions, et trois filières de Master (Economie, Biologie, Intelligence Artificielle) figurent parmi les cinq premières.

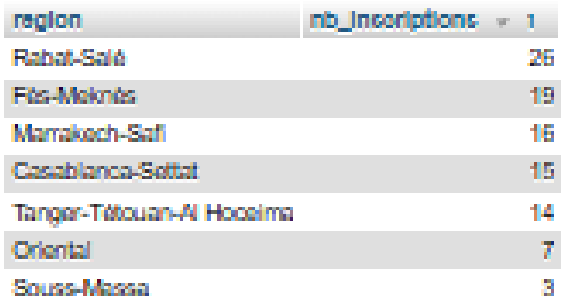
nom_filiere	niveau	nb_inscriptions ▼ 1
Économie	Master	15
Marketing	Licence	13
Biologie	Master	13
Informatique	Licence	12
Intelligence Artificielle	Master	12
Mathématiques	Licence	11
Droit Privé	Licence	9
Gestion	Licence	7
Réseaux	Master	6
Physique	Licence	2

Figure 16 : Inscriptions par filière

Inscriptions par région

```
SELECT g.region, COUNT(*) AS nb_inscriptions
FROM fait_inscription fi
JOIN dim_geographie g ON fi.id_geo = g.id_geo
GROUP BY g.region
ORDER BY nb_inscriptions DESC;
```

Rabat-Salé domine avec 26 inscriptions (elle regroupe Rabat et Kenitra), devant Fès-Meknès (19) et Marrakech-Safi (16). Souss-Massa, qui ne compte qu'Agadir, ferme la liste avec 3 inscriptions. Ce résultat n'est fiable que grâce à la correction des régions. La somme des sept régions est de 100.



region	nb_inscriptions
Rabat-Salé	26
Fès-Meknès	19
Marrakech-Safi	16
Casablanca-Settat	15
Tanger-Tétouan-Al Hoceima	14
Oriental	7
Souss-Massa	3

Figure 17 : Inscriptions par région

Taux de redoublement global

```
SELECT ROUND(100 * SUM(s.type_statut = 'Redoublant') / COUNT(*), 2)
       AS taux_redoublement_pct
FROM fait_inscription fi
JOIN dim_statut s ON fi.id_statut = s.id_statut;
```

C'est la part des inscriptions « Redoublant » sur toutes les inscriptions (désistés inclus). Le résultat est de **17 %** : 17 inscriptions sur 100 sont des redoublements.



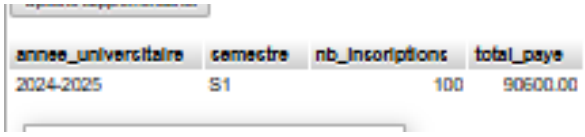
taux_redoublement_pct
17.00

Figure 18 : Taux de redoublement global

Inscriptions par année universitaire et semestre

```
SELECT t.annee_universitaire, t.semestre, COUNT(*) AS nb_inscriptions,
       SUM(fi.montant_paye) AS total_paye
FROM fait_inscription fi
JOIN dim_temps t ON fi.id_temps = t.id_temps
GROUP BY t.annee_universitaire, t.semestre;
```

Toutes les inscriptions datent de septembre-octobre 2024 : on attend donc une seule ligne (2024-2025, S1). C'est bien ce qui apparaît : une seule ligne, avec **100 inscriptions** et un total payé de **90 600**. L'évolution entre plusieurs années ne peut donc pas être montrée avec ces données.



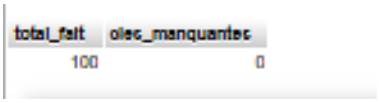
annee_universitaire	semestre	nb_inscriptions	total_paye
2024-2025	S1	100	90600.00

Figure 19 : Inscriptions par année universitaire et semestre

Contrôle du chargement

```
SELECT COUNT(*) AS total_fait,
       SUM(id_geo IS NULL OR id_statut IS NULL OR id_temps IS NULL) AS cles_manquantes
FROM fait_inscription;
```

Cette requête confirme que fait_inscription contient **100 lignes** et qu'aucune clé étrangère n'est vide (**0 clé manquante**) : tous les lookups ont trouvé leur ligne dans les dimensions.



total_fait	cles_manquantes
100	0

Figure 20 : Contrôle du nombre de lignes et des clés manquantes

Conclusion

J'ai construit un entrepôt de cinq dimensions et d'une table de faits, alimenté par six jobs Talaxie à partir de trois fichiers Excel. La correction de la région était indispensable pour que la répartition par région soit juste. Pour aller plus loin, il faudrait un job principal qui enchaîne les chargements, des données sur plusieurs années, et une validation des doublons et des montants à 0.